



TRƯỜNG ĐẠI HỌC BÁCH KHOA – ĐHQG-HCM

BÁO CÁO ĐỒ ÁN TỔNG HỢP

Hướng Trí tuệ Nhân tạo

*Xử lý bài toán Phân loại khối U não với Đa phương pháp:
Naive Bayes, Random Forest,
MultiClassSVM One-vs-One và CNNs*

Giảng viên hướng dẫn: Trần Nguyễn Minh Duy

Sinh viên thực hiện: Nguyễn Duy Tân – 2313054

Nguyễn Trần Anh Quân – 2312845

Nguyễn Thành Nam – 2312180

Vũ Huy Gia Khang – 2311486

Table of Content

I	Giới thiệu đề tài	V
II	Các công trình liên quan	VI
III	Dataset và Evaluation Metrics	VII
IV	Phương pháp thực hiện và Kết quả thực nghiệm	
V	Kết luận	

I. Giới thiệu đề tài

I. Giới thiệu đề tài

Lý do chọn đề tài

❖ **Thực trạng:**

- ❑ U não là bệnh nguy hiểm, tỷ lệ tử vong cao, ảnh hưởng nghiêm trọng sức khỏe.
- ❑ Chẩn đoán chính xác đóng vai trò then chốt trong điều trị và tiên lượng.

❖ **Vấn đề tồn tại:**

- ❑ Phương pháp truyền thống dựa vào ảnh MRI và đánh giá thủ công của bác sĩ.
- ❑ Nhược điểm: Tốn thời gian, mang tính chủ quan và có thể xảy ra sai sót.

❖ **Giải pháp:**

- ❑ Ứng dụng Trí tuệ nhân tạo (AI), Học máy (ML) và Học sâu (DL) để hỗ trợ chẩn đoán khách quan và chính xác hơn.

II. Các công trình liên quan

II. Các công trình liên quan

Các nghiên cứu gần đây cho thấy mô hình CNN mang lại kết quả tốt trong phân loại ảnh MRI não, giúp nhận diện loại u nhanh và chính xác hơn so với bác sĩ thủ công. Một số nhóm dùng SVM hay Random Forest để so sánh, nhưng các mô hình này phụ thuộc nhiều vào bước trích đặc trưng thủ công nên hiệu quả thấp hơn. Trong thực tế, CNN được xem là lựa chọn phổ biến và hiệu quả nhất cho bài toán phân loại khối u não hiện nay.

III. Dataset và Evaluation Metrics

III. Dataset và Evaluation Metrics


Dataset

- Bộ dữ liệu sử dụng là **BRISC 2025 Dataset**, được lấy từ Kaggle
- Nhóm chỉ sử dụng phần **task Classification** của bộ dữ liệu.
- Dữ liệu bao gồm ảnh MRI não người, được chia thành 4 lớp: **no_tumor**, **glioma**, **meningioma**, và **pituitary**.
- Tổng số ảnh : **6000** tấm (train: **5000**, test: **1000**), định dạng chủ yếu là **.jpg**.
- Kích thước ảnh gốc **512×512 pixel**, chỉ gồm **ảnh màu**.
- Ảnh được chụp từ nhiều góc độ và lát cắt **MRI khác nhau**, thể hiện rõ cấu trúc vùng não và khối u.
- Một số ảnh có **nhiều** hoặc **độ sáng không đồng đều**, phản ánh dữ liệu y tế thực tế.
- Số lượng ảnh giữa các lớp **không hoàn toàn cân bằng**.


III. Dataset và Evaluation Metrics

Dataset


glioma




meningioma



no_tumor



pituitary



III. Dataset và Evaluation metrics

Evaluation metrics

- ❖ **Mục tiêu:** Đánh giá hiệu quả từng mô hình và so sánh hiệu năng của chúng trên tập dữ liệu kiểm thử (test set).
- ❖ Các trường hợp dự đoán:
 - ❑ **True Positive (TP):** mẫu thuộc lớp *Positive*, mô hình dự đoán *Positive*
 - ❑ **True Negative (TN):** mẫu thuộc lớp *Negative*, mô hình dự đoán *Negative*
 - ❑ **False Positive (FP):** mẫu thuộc lớp *Negative*, mô hình dự đoán *Positive*
 - ❑ **False Negative (FN):** mẫu thuộc lớp *Positive*, mô hình dự đoán *Negative*

III. Dataset và Evaluation metrics

Evaluation metrics

Accuracy:

- Công thức: $Accuracy = \frac{CorrectPrediction}{TotalPrediction}$
- Ý nghĩa: Mức độ đúng đắn tổng thể của mô hình.

Precision:

- Công thức: $Precision_i = \frac{TP_i}{TP_i + FP_i}$
- Ý nghĩa: Trong các mẫu được mô hình dự đoán là lớp i , có bao nhiêu % thực sự là lớp i .

Recall:

- Công thức: $Recall_i = \frac{TP_i}{TP_i + FN_i}$
- Ý nghĩa: Trong các mẫu thực tế là lớp i , mô hình nhận diện được bao nhiêu %.


F1-score:

- Công thức: $F1_i = \frac{Precision_i \cdot Recall_i}{Precision_i + Recall_i}$
- Ý nghĩa: Chỉ số điều hòa giữa Precision và Recall.

IV. Phương pháp thực hiện và Kết quả thực nghiệm

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Pipeline



IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Preprocessing

- ❖ Chuyển đổi: RGB sang Grayscale.
- ❖ Resize: Đưa về kích thước chuẩn 224×224 pixels.
- ❖ Normalization: Chuyển đổi giá trị pixel về đoạn $[0, 1]$

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Trích xuất đặc trưng bằng HOG kết hợp PCA

Histogram of Oriented Gradients (HOG)

- ❖ **Khái niệm:** Đặc trưng mô tả hình dạng dựa trên phân bố hướng gradient cục bộ.
- ❖ **Ứng dụng tiêu biểu:** Nhận diện người đi bộ (Human Detection).
- ❖ **Tính toán Gradient:**
 - *Đạo hàm bậc nhất:*

$$\begin{aligned}g_x &= I(x + 1, y) - I(x - 1, y), \\g_y &= I(x, y + 1) - I(x, y - 1)\end{aligned}$$

- *Độ lớn (m) và hướng (θ):*

$$\begin{aligned}m &= \sqrt{g_x^2 + g_y^2}, \\ \theta &= \arctan\left(\frac{g_y}{g_x}\right)\end{aligned}$$

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Trích xuất đặc trưng bằng HOG kết hợp PCA

Quy trình thực hiện HOG

- ❖ **Chia cell:** Chia ảnh thành các ô nhỏ (ví dụ 8×8 pixels)
- ❖ **Tạo histogram:** Mỗi cell tính toán một histogram hướng dựa trên giá trị của (m) và (θ)
- ❖ **Gom block và chuẩn hóa:**
 - ❑ Gom các cell thành các khối lớn hơn để chuẩn hóa vùng
 - ❑ Sử dụng L_2 để giảm ảnh hưởng của độ sáng:

$$v' = \frac{v}{\sqrt{\|v\|_2^2 + \epsilon^2}}$$






- ❖ **Vector đặc trưng:** Ghép nối các vector từ các khối để đưa vào các bộ phân loại

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Trích xuất đặc trưng bằng HOG kết hợp PCA

Ưu điểm nổi bật của HOG

- ❖ Mô tả tốt cấu trúc biên và hướng cạnh
- ❖ **Bất biến (Invariant):** Ổn định trước thay đổi ánh sáng và các biến dạng nhỏ.



IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Trích xuất đặc trưng bằng HOG kết hợp PCA

Phân tích thành phần chính (PCA)

- ❖ Phương pháp giảm chiều dữ liệu (Dimensionality Reduction) mà vẫn giữ lại tối đa lượng thông tin (phương sai).
- ❖ Mục tiêu:
 - ❑ Tìm các trục tọa độ mới (**Principal Components**) sao cho dữ liệu biến thiên mạnh nhất trên đó.
 - ❑ Loại bỏ các thành phần có ít biến động (thường là nhiễu).
- ❖ **Ví dụ:** Chiếu dữ liệu từ 3D xuống 2D hoặc 2D xuống 1D mà không làm mất đi *hình dáng* đặc trưng của cụm dữ liệu.

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Trích xuất đặc trưng bằng HOG kết hợp PCA

Cách hoạt động của PCA

- ❖ Tiền xử lý: Chuẩn hóa dữ liệu X (zero-mean).
- ❖ Ma trận hiệp phương sai: Tính toán để tìm mối tương quan giữa các chiều

$$\Sigma = \frac{1}{n} X^T X$$

- ❖ Phân rã (EVD/SVD): Tìm các trị riêng λ_i biểu thị lượng phương sai (thông tin) trên trục đó và vector riêng v_i là hướng của các thành phần chính.
- ❖ Phép chiếu: Ánh xạ dữ liệu sang không gian có chiều thấp hơn

$$Z = XV$$

Trong đó V là ma trận chứa k vector riêng tương ứng với k trị riêng lớn nhất.

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Soft-Margin SVM: Nền tảng phân lớp nhị phân

- ❖ **Mục tiêu:** Tìm siêu phẳng (hyperplane) tối ưu để phân tách 2 lớp với lề (margin) lớn nhất.
- ❖ **Bài toán tối ưu (Primal Form):**

$$(\mathbf{w}, b, \xi) = \arg \min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \cdot \sum_{n=1}^N \xi_n$$

Trong đó

$$\begin{aligned} 1 - \xi_n - y_n(\mathbf{w}^T \mathbf{x}_n + b) &\leq 0, n = 1, \dots, N \\ -\xi_n &\leq 0, n = 1, \dots, N \end{aligned}$$

Và ξ_n được gọi là biến Slack

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Chiến lược đa lớp One-vs-One (OVO)

❖ **Nguyên lý:** Chia bài toán k lớp thành các cặp bài toán nhị phân.

❖ Số lượng bộ phân lớp:

$$N = \frac{k(k - 1)}{2}$$

❖ Số lượng bộ phân lớp:

❑ Glioma vs Meningioma

❑ Glioma vs No_tumor

❑ ...

❖ **Ưu điểm:** Mỗi bộ SVM chỉ huấn luyện trên tập con dữ liệu $\Rightarrow$ Giảm tải tính toán cho mỗi model thành phần.

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Dự đoán và Chiến lược bỏ phiếu Max Wins

❖ Quy trình dự đoán:

1. Đưa mẫu thử x_{test} qua tất cả $N = \frac{k(k-1)}{2}$ bộ SVM.
2. Mỗi SVM dự đoán một nhãn (bỏ 1 phiếu cho lớp thắng).
3. Lớp có **tổng số phiếu cao nhất** sẽ được chọn làm kết quả cuối cùng.

❖ Xử lý hòa (Tie-breaker):

Nếu hai lớp có số phiếu bằng nhau, sử dụng **Tổng điểm tin cậy** (Confidence score):

$$\hat{y} = \arg \max \sum |s_{ij}|$$

Trong đó s_{ij} là khoảng cách từ điểm dữ liệu đến siêu phẳng.

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Kernel Trick: Ánh xạ không gian đặc trưng

- ❖ **Vấn đề:** Dữ liệu ban đầu (HOG features) thường không phân tách tuyến tính.
- ❖ **Giải pháp:** Ánh xạ dữ liệu vào không gian cao chiều $\phi(x)$ nơi chúng có thể phân tách được.
- ❖ RBF Kernel (Radial Basis Function):

$$K(x, z) = \exp\left(-\gamma ||x - z||^2\right)$$

- ❑ Tham số γ : Kiểm soát tầm ảnh hưởng của một mẫu huấn luyện đơn lẻ.
- ❑ γ cao: Biên quyết định bám sát dữ liệu (linh hoạt nhưng dễ nhiễu).
- ❑ γ thấp: Biên quyết định mượt hơn.

IV. Phương pháp thực hiện Support Vector Machine – One-vs-One

Kết quả và đánh giá

	precision	recall	f1-score	support
glioma	0.98	0.94	0.96	254
meningioma	0.95	0.96	0.95	306
no_tumor	0.97	0.99	0.98	140
pituitary	0.99	1.00	0.99	300
accuracy			0.97	1000
macro avg	0.97	0.97	0.97	1000
weighted avg	0.97	0.97	0.97	1000
Overall Accuracy: 97.00%				

IV. Phương pháp thực hiện

Support Vector Machine – One-vs-One

Kết quả và đánh giá

- ❖ **Độ chính xác ấn tượng:** Mô hình dự đoán đúng **970 trên tổng số 1000** mẫu thử.
- ❖ **Hiệu suất cân bằng tuyệt đối:** Các chỉ số *Macro avg* và *Weighted avg* đều đạt **0.97**, cho thấy sự ổn định đồng đều trên tất cả các loại u.
- ❖ **Kháng lại sự mất cân bằng dữ liệu:** Dù số lượng mẫu giữa các lớp có sự chênh lệch lớn (ví dụ: *No tumor* 140 mẫu vs. *Meningioma* 306 mẫu), mô hình vẫn duy trì độ chính xác cực cao ở mọi lớp.
- ❖ **Khả năng nhận diện hoàn hảo:** Lớp *Pituitary* đạt Recall **1.00**, nghĩa là không bỏ sót bất kỳ mẫu u tuyến yên nào trong tập test.

IV. Phương pháp thực hiện

Naïve Bayes

Tổng quan về Naïve Bayes

. Cơ sở lý thuyết:

_ Dựa trên định lý Bayes về xác suất thống kê:

$$P(y|X) = \frac{P(X|y) \cdot P(y)}{P(X)}$$

_ **Giả định "Ngây thơ" (Naive):** Các đặc trưng đầu vào (features) độc lập với nhau trong mỗi lớp.

. Ưu điểm:

- _ Tốc độ huấn luyện và dự đoán rất nhanh.
- _ Hoạt động tốt với dữ liệu ít, dễ cài đặt.
- _ Ít bị ảnh hưởng bởi nhiễu (noise) khi giảm chiều dữ liệu.

. Nhược điểm:

- _ Giả định các đặc trưng độc lập hiếm khi đúng trong thực tế (đặc biệt là các pixel trong ảnh có quan hệ chặt chẽ).
- _ Độ chính xác thường thấp hơn các mô hình phức tạp (như CNN) trong bài toán thị giác máy tính.

IV. Phương pháp thực hiện

Naïve Bayes

3 biến thể của Naïve Bayes

1. Gaussian Naive Bayes:

_ Dùng khi các đặc trưng là số thực liên tục và tuân theo phân phối chuẩn (Gaussian).

_ Áp dụng trong đề tài: Được lựa chọn sử dụng vì đặc trưng sau khi trích xuất (PCA) là các giá trị thực liên tục.

2. Multinomial Naive Bayes:

Dùng cho dữ liệu dạng đếm (ví dụ: số lần từ xuất hiện trong văn bản).


3. Bernoulli Naive Bayes:

Dùng cho dữ liệu nhị phân (0/1).

IV. Phương pháp thực hiện

Naïve Bayes

Pipeline



IV. Phương pháp thực hiện

Naïve Bayes

Tiền xử lý dữ liệu (Preprocessing)

Bước 1: Chuyển đổi màu (Grayscale)

- _ Mô hình không cần thông tin màu sắc để phát hiện cấu trúc khối u.
- _ Sử dụng hàm `rgb2gray` để chuyển ảnh 3 kênh sang 1 kênh.

Bước 2: Resize ảnh

- _ Đưa tất cả ảnh về cùng kích thước chuẩn: **64 x 64 pixels**.
- _ Mục đích: Giảm khối lượng tính toán và đồng bộ hóa đầu vào cho thuật toán HOG.

IV. Phương pháp thực hiện

Naïve Bayes

Trích xuất đặc trưng (HOG & PCA)

1. Histogram of Oriented Gradients (HOG):

_ Mục đích: Trích xuất đặc trưng hình dáng và biên cạnh của khối u.

_ Tham số cấu hình:

- orientations: 9 (hướng gradient).
- pixels_per_cell: (8, 8).
- cells_per_block: (2, 2).

2. Principal Component Analysis (PCA):

_ Mục đích: Giảm số lượng đặc trưng khổng lồ từ HOG để tránh Overfitting và tăng tốc độ.

_ Cấu hình: n_components = 100.

_ Giữ lại 100 thành phần quan trọng nhất chứa nhiều thông tin biến thiên (Variance) nhất.

IV. Phương pháp thực hiện

Naïve Bayes

Kết quả và Đánh giá

- _ Mô hình đạt accuracy **74.1%**, cho thấy khả năng phân loại ở mức trung bình khá.
- _ Hai lớp **pituitary** và **no_tumor** đạt hiệu quả tốt nhất với độ nhạy (**Recall**) rất cao, đều đạt **0.92**.
- _ Lớp **meningioma** có kết quả thấp nhất (**Recall 0.51**), mô hình bỏ sót gần một nửa số mẫu thật và thường nhầm lẫn với **glioma** hoặc **pituitary**.
- _ Các chỉ số trung bình (**macro và weighted**) dừng lại ở mức **0.73 - 0.74**, phản ánh sự mất cân bằng hiệu suất đáng kể, cần cải thiện khả năng nhận diện lớp meningioma.
- _ **Test loss** đạt giá trị thấp (**0.6883**), cho thấy xác suất dự đoán của mô hình tương đối ổn định và không quá sai lệch.


IV. Phương pháp thực hiện Naïve Bayes

Kết quả và Đánh giá

	precision	recall	f1-score	support
glioma	0.80	0.71	0.75	254
meningioma	0.65	0.51	0.57	306
no_tumor	0.72	0.92	0.81	140
pituitary	0.78	0.92	0.84	300
accuracy			0.74	1000
macro avg	0.74	0.76	0.74	1000
weighted avg	0.74	0.74	0.73	1000


Overall Accuracy: 74.10%

Test Loss: 68.83%



IV. Phương pháp thực hiện Random Forest

Pipeline



IV. Phương pháp thực hiện


Random Forest

Trích xuất đặc trưng bằng HOG kết hợp PCA

- HOG: tương tự như mô hình SVM, mô tả đặc trưng hình dạng và cấu trúc dựa trên độ lớn và hướng gradient cục bộ trong ảnh.
- PCA: nén không gian dữ liệu bằng cách tìm các trục chính mang nhiều thông tin nhất, loại bỏ các đặc trưng thừa.

IV. Phương pháp thực hiện Random Forest

Mô hình Random Forest



❖ Đặc trưng của Random Forest:

- ❑ **Bootstrap Sampling:** Rút trích dữ liệu ngẫu nhiên (có hoàn lại) từ tập huấn luyện gốc để tạo ra các tập dữ liệu con khác nhau cho mỗi cây.
- ❑ **Random Feature Selection:** Tại mỗi nút chia, chỉ chọn một tập con ngẫu nhiên các đặc trưng để phân chia thay vì toàn bộ đặc trưng.

❖ Tham số tối ưu sau khi chạy RadomizedSearchCV:

- ❑ **n_estimators** = 200
- ❑ **max_depth** = 20
- ❑ **max_features** = 'sqrt'
- ❑ **min_samples_split** = 4
- ❑ **min_samples_leaf** = 2

IV. Phương pháp thực hiện

Random Forest

Kết quả và đánh giá

- ❖ Mô hình đạt accuracy **91%**, cho thấy khả năng phân loại ổn định và hiệu quả.
- ❖ Hai lớp **pituitary** và **no_tumor** đạt kết quả tốt nhất với **F1-score** lần lượt là **0.95** và **0.98**.
- ❖ Lớp **glioma** có **recall** thấp nhất (**0.83**), cho thấy mô hình vẫn bỏ sót một số mẫu thật (false negative), thường nhầm với lớp **meningioma**.
- ❖ Các chỉ số trung bình (**macro** và **weighted**) đều đạt khoảng **0.91-0.92**, chứng tỏ mô hình hoạt động ổn định, không bị lệch về một lớp cụ thể


	precision	recall	f1-score	support
glioma	0.93	0.83	0.88	254
meningioma	0.86	0.88	0.87	306
no_tumor	0.97	0.99	0.98	140
pituitary	0.93	0.98	0.95	300
accuracy			0.91	1000
macro avg	0.92	0.92	0.92	1000
weighted avg	0.91	0.91	0.91	1000

Test Loss: 0.4130

Overall Accuracy: 91.20%

IV. Phương pháp thực hiện Convolutional Neural Network

Pipeline



Preprocessing

- Resize(224, 224)
- RandomCrop
- RandomHorizontalFlip
- RandomErasing
- Normalize

IV. Phương pháp thực hiện Convolutional Neural Network


Mô hình CNN from scratch

- Kiến trúc cơ bản của một CNN thường bao gồm các thành phần:
 - Lớp Convolution (Conv Layer): thực hiện phép tích chập giữa bộ lọc (kernel) và ảnh đầu vào để phát hiện đặc trưng cục bộ.
 - Lớp Pooling: giảm kích thước không gian của đặc trưng, giúp giảm số lượng tham số và hạn chế overfitting.
 - Lớp Activation (ReLU): giới thiệu tính phi tuyến vào mô hình, giúp mạng học các mối quan hệ phức tạp.
 - Lớp Fully Connected (FC): kết hợp các đặc trưng đã học để thực hiện phân loại cuối cùng.

IV. Phương pháp thực hiện Convolutional Neural Network

Mô hình CNN from scratch

- Lấy cảm ý tưởng từ kỹ thuật **skip connection** của kiến trúc **ResNet** , nhóm đã phát triển một mô hình CNN tự thiết kế có:
- Total params: **139,540,548**
- Trainable params: **139,540,548**



IV. Phương pháp thực hiện

Convolutional Neural Network

Mô hình CNN from scratch

- Mô hình được huấn luyện trong **20 epoch** với **batch size = 32**.
- Sử dụng **learning rate = 0.001** cùng bộ tối ưu Adam để cập nhật trọng số.
- Hàm mất mát được chọn là **CrossEntropyLoss**, phù hợp cho bài toán phân loại nhiều lớp.

V. Kết luận

IV. Kết luận

Tổng kết kết quả đạt được

Bảng 6: So sánh hiệu năng giữa các mô hình phân loại khối u não trên bộ dữ liệu BRISC 2025

Mô hình	Đặc trưng / Kiến trúc	Độ chính xác (Accuracy)
MultiClassSVM OVO	HOG + PCA	97.00%
Random Forest	HOG + PCA	91.20%
CNN	ResNet-inspired (Skip connections)	90.60%
Naive Bayes	GaussianNB + PCA	74.10%

IV. Kết luận

Nhận xét và Đánh giá

Sự vượt trội của SVM (97%)

- ❖ Kết hợp HOG giúp mô tả cực tốt cấu trúc biên và hướng cạnh của khối u.
- ❖ Với kích thước tập dữ liệu hiện tại, trích xuất đặc trưng thủ công vẫn mang lại hiệu quả cao hơn học sâu.

Đặc tính của Random Forest

- ❖ Hoạt động rất ổn định trên các lớp có hình thái rõ ràng (Pituitary, No Tumor) với F1-score đạt 0.98

Hạn chế của CNN & Naive Bayes

- ❖ **CNN:** Hiệu suất lớp Glioma còn thấp (Recall 0.80), cần tăng cường dữ liệu hoặc tinh chỉnh thêm kiến trúc
- ❖ **Naive Bayes:** Bị giới hạn bởi giả định độc lập giữa các đặc trưng, dẫn đến Recall thấp ở lớp Meningioma (0.51).

IV. Kết luận

Hướng phát triển tương lai

Tối ưu hóa mô hình

- ❖ Thử nghiệm kiến trúc **Vision Transformers (ViT)** hoặc **Transfer Learning** từ các tập dữ liệu y tế lớn.
- ❖ Xây dựng mô hình **Ensemble Learning** (kết hợp SVM và CNN) để tận dụng cả đặc trưng thủ công và tự động.

Tính minh bạch & Tin cậy

- ❖ Áp dụng **Explainable AI (Grad-CAM)** để bác sĩ có thể quan sát vùng u mà mô hình đang tập trung phân tích.

Dữ liệu thực tế

- ❖ Mở rộng tập dữ liệu từ nhiều nguồn khác nhau để đảm bảo tính tổng quát hóa trước các biến thể về nhiễu và độ sáng.



THANK YOU